

PROMPT ENGINEERING

Guía técnica completa: de los fundamentos a las técnicas avanzadas

Documento técnico de referencia

Septiembre de 2026

Fundamentos de los modelos de lenguaje · Técnicas de prompting · Agentes y herramientas RAG · Seguridad · Evaluación
· Ejemplos en Python y C

Índice

1. Introducción	4
1.1 ¿Qué es un prompt y qué es el prompt engineering?	4
1.2 Breve contexto técnico: de los modelos de lenguaje a los LLM conversacionales	4
1.3 ¿Por qué importa el prompt engineering?	5
1.4 Cómo está organizado este documento	5
2. Fundamentos: cómo "piensa" un modelo de lenguaje	6
2.1 La tarea subyacente: predicción del siguiente token	6
2.2 Tokens y tokenización	7
2.3 La ventana de contexto	8
2.4 Parámetros de generación: temperature, top-p y top-k	8
2.5 Roles de la conversación: system, user y assistant	10
3. Anatomía y principios de un buen prompt	12
3.1 Componentes de un prompt eficaz	12
3.2 Claridad, especificidad y el principio de la "carga cognitiva cero"	13
3.3 El papel del formato de salida	14
3.4 Antipatrones frecuentes	14
4. Técnicas fundamentales de prompting	16
4.1 Zero-shot prompting	16
4.2 One-shot y few-shot prompting	16
4.3 Prompting basado en roles y persona	17
4.4 Plantillas y prompts parametrizados	18
5. Razonamiento explícito: técnicas intermedias	20
5.1 Chain-of-Thought (CoT): cadena de pensamiento	20
5.2 Zero-shot CoT: "pensemos paso a paso"	21
5.3 Self-Consistency: autoconsistencia	21
5.4 Prompt Chaining: encadenamiento de prompts	22
5.5 Least-to-Most prompting	23
6. Técnicas avanzadas de agentes y razonamiento	25
6.1 ReAct: razonar y actuar	25
6.2 Tree of Thoughts (ToT): árbol de pensamientos	26
6.3 Function calling y uso de herramientas	27
6.4 RAG: generación aumentada por recuperación	29
6.5 Arquitecturas multiagente	30
6.6 Meta-prompting y optimización automática de prompts	31
7. Prompt engineering aplicado a la programación	33
7.1 Generación de código	33
7.2 Depuración y explicación de errores	33
7.3 Refactorización y revisión de código	34
7.4 Generación de tests	35
7.5 Integración desde Python: ejemplo completo con la API de mensajes	36
7.6 Integración desde C: llamadas HTTP con libcurl y construcción de JSON	37
8. Evaluación, iteración y control de calidad de prompts	41

8.1 Por qué evaluar los prompts de forma sistemática	41
8.2 Métricas y criterios de evaluación	41
8.3 Metodología de iteración.....	42
8.4 Testing automatizado y regresión de prompts	42
9. Seguridad, riesgos y buenas prácticas.....	44
9.1 Prompt injection: inyección de prompts.....	44
9.2 Jailbreaking y mitigaciones.....	45
9.3 Fuga de información y protección del system prompt	45
9.4 Alucinaciones, confabulación y sesgos	46
9.5 Buenas prácticas de seguridad: resumen	46
10. Herramientas y el ecosistema de prompt engineering.....	48
10.1 SDKs y API de los principales proveedores	48
10.2 Frameworks de orquestación.....	48
10.3 Gestión de prompts en producción	49
11. Casos prácticos completos	50
11.1 Caso 1: asistente de atención al cliente con RAG	50
11.2 Caso 2: pipeline de extracción estructurada de datos.....	50
11.3 Caso 3: agente de análisis de código con herramientas	51
12. Checklist final de buenas prácticas	53
13. Glosario de términos	54
14. Referencias y lecturas recomendadas.....	56

1. Introducción

1.1 ¿Qué es un prompt y qué es el prompt engineering?

Un **prompt** es el texto de entrada que se envía a un modelo de lenguaje para obtener una respuesta. Puede ser tan simple como una pregunta de una línea o tan complejo como un documento estructurado con instrucciones, contexto, ejemplos y restricciones de formato. El **prompt engineering** (ingeniería de prompts) es la disciplina que estudia cómo diseñar, estructurar y refinar ese texto de entrada para maximizar la calidad, fiabilidad y utilidad de la respuesta generada por el modelo.

A diferencia de la programación tradicional, donde el comportamiento de un sistema se define mediante instrucciones formales y deterministas (código fuente en C, Python, etc.), un modelo de lenguaje de gran escala (LLM, *Large Language Model*) se comporta como una función probabilística entrenada sobre enormes cantidades de texto. No se “programa” en el sentido clásico: se **condiciona** su comportamiento mediante el lenguaje natural. Esto convierte el prompt en la interfaz de programación (API) más importante y, a la vez, en la más ambigua de todo el sistema.

IDEA CLAVE

El prompt engineering no consiste en “hablarle bonito” a un modelo: es una disciplina de ingeniería con principios reproducibles, técnicas evaluables y buenas prácticas contrastadas empíricamente, muy similar en espíritu a la ingeniería de requisitos o al diseño de APIs.

1.2 Breve contexto técnico: de los modelos de lenguaje a los LLM conversacionales

Los modelos de lenguaje llevan décadas siendo objeto de estudio en el procesamiento del lenguaje natural (PLN). Los primeros modelos estadísticos (n-gramas) estimaban la probabilidad de una palabra a partir de las palabras anteriores mediante conteos de frecuencias. Con la llegada de las redes neuronales recurrentes (RNN) y, más tarde, de las redes LSTM, se logró capturar dependencias de más largo alcance, aunque con limitaciones importantes de paralelización y de memoria efectiva.

El punto de inflexión llega en 2017 con la arquitectura **Transformer**, que sustituye la recurrencia por un mecanismo de **autoatención** (*self-attention*) capaz de relacionar directamente cualquier posición de una secuencia con cualquier otra, sin importar la distancia entre ellas, y de forma altamente paralelizable en GPU/TPU. Sobre esta arquitectura se han entrenado los modelos que hoy conocemos como LLM: modelos con miles de millones (o billones) de parámetros, entrenados sobre corpus de texto e incluso código, imágenes o audio, y ajustados posteriormente mediante técnicas como el ajuste fino supervisado (*supervised fine-tuning*, SFT) y el aprendizaje por refuerzo con retroalimentación humana (*RLHF*, *Reinforcement Learning from Human Feedback*) para que sigan instrucciones de forma útil, honesta e inocua.

Es precisamente ese ajuste para “seguir instrucciones” lo que ha hecho posible el prompt engineering tal y como lo conocemos: modelos que no solo completan texto de forma estadística, sino que interpretan una instrucción en lenguaje natural y actúan en consecuencia.

1.3 ¿Por qué importa el prompt engineering?

La forma en que se formula un prompt tiene un impacto medible y a menudo muy grande sobre la calidad de la respuesta: exactitud factual, coherencia lógica, adherencia al formato solicitado, tono, seguridad y coste (en tokens y en tiempo de inferencia). Un mismo modelo puede pasar de un rendimiento mediocre a un rendimiento sobresaliente en una tarea concreta simplemente reformulando el prompt, sin modificar ni un parámetro del modelo. Entre las razones principales por las que esta disciplina se ha vuelto imprescindible en cualquier equipo que integre LLM en sus productos destacan las siguientes:

- **Coste y latencia:** prompts mal diseñados consumen más tokens de los necesarios, incrementan el coste por llamada a la API y aumentan la latencia percibida por el usuario.
- **Fiabilidad:** una estructura de prompt adecuada reduce la variabilidad de las respuestas y la probabilidad de alucinaciones (afirmaciones plausibles pero falsas).
- **Seguridad:** un prompt bien construido, junto con las salvaguardas adecuadas, reduce la superficie de ataque frente a intentos de manipulación (*prompt injection*, *jailbreaking*).
- **Mantenibilidad:** los prompts de producción evolucionan como el código: se versionan, se prueban y se documentan.
- **Portabilidad limitada entre modelos:** cada familia de modelos responde de forma distinta a determinadas construcciones, por lo que entender los principios subyacentes permite adaptar prompts entre proveedores con mayor rapidez que reescribirlos desde cero.

1.4 Cómo está organizado este documento

El documento avanza de forma progresiva, de lo más elemental a lo más avanzado, y está pensado tanto para quien se inicia en el diseño de prompts como para quien ya integra LLM en sistemas de producción y busca profundizar en técnicas de razonamiento, uso de herramientas, arquitecturas multiagente, evaluación y seguridad. Dado el perfil técnico del lector, se incluyen ejemplos de código en **Python** —el lenguaje más habitual para interactuar con las API de los proveedores de modelos— y también en **C**, para quienes necesiten integrar llamadas a un LLM en sistemas de bajo nivel o con restricciones de entorno.

- **Capítulos 2 y 3:** fundamentos técnicos (tokenización, ventana de contexto, muestreo) y anatomía de un buen prompt.
- **Capítulos 4 y 5:** técnicas fundamentales e intermedias de prompting (zero-shot, few-shot, cadena de pensamiento, autoconsistencia, encadenamiento de prompts).
- **Capítulo 6:** técnicas avanzadas (ReAct, árbol de pensamientos, uso de herramientas, RAG, sistemas multiagente, meta-prompting).
- **Capítulo 7:** aplicación práctica a tareas de programación, con ejemplos en Python y en C.

- **Capítulos 8 y 9:** evaluación sistemática de prompts y seguridad (inyección de prompts, jailbreaking, sesgos).
- **Capítulos 10 y 11:** ecosistema de herramientas y casos prácticos completos de extremo a extremo.
- **Capítulo 12 y siguientes:** checklist final, glosario de términos y referencias.

2. Fundamentos: cómo "piensa" un modelo de lenguaje

Antes de entrar en técnicas concretas de prompting conviene entender, aunque sea a alto nivel, qué ocurre técnicamente cuando un LLM recibe un prompt. Comprender estos fundamentos permite diseñar prompts con criterio en lugar de por ensayo y error, y explica por qué determinadas construcciones funcionan sistemáticamente mejor que otras.

2.1 La tarea subyacente: predicción del siguiente token

En su núcleo, un LLM moderno de tipo *decoder-only* (la arquitectura empleada por la inmensa mayoría de los asistentes conversacionales actuales) resuelve una única tarea: dada una secuencia de tokens, estimar la distribución de probabilidad del **siguiente token**. La generación de un texto completo se realiza de forma **autorregresiva**: el modelo predice un token, lo añade a la secuencia de entrada, y vuelve a predecir el siguiente, repitiendo el proceso hasta alcanzar un token de fin de secuencia o un límite de longitud.




Figura 1. Arquitectura simplificada de un modelo de lenguaje autorregresivo de tipo Transformer *decoder-only*.

Cada bloque Transformer combina dos componentes principales: un mecanismo de **autoatención multi-cabeza**, que permite que cada token "atienda" a los demás tokens del contexto y pondere su relevancia, y una **red feed-forward** que transforma esa representación de forma no lineal. Ambos componentes se envuelven en conexiones residuales y normalización, y el bloque se apila decenas de veces (de ahí que se hable de modelos con "N capas"). Esta arquitectura es la que permite a los

modelos capturar relaciones sintácticas y semánticas complejas entre palabras alejadas en el texto, algo que resulta clave para que un prompt largo, con contexto e instrucciones al principio, siga influyendo correctamente en un texto generado muchos tokens después.

NOTA

Que el modelo trabaje "un token cada vez" tiene una consecuencia práctica directa: si se le pide que dé primero una conclusión y después la justifique, el modelo ya se ha "comprometido" con esa conclusión antes de razonar sobre ella. Por eso, en tareas complejas, suele funcionar mejor pedir el razonamiento antes que la respuesta final (véase el capítulo 5, sobre Chain-of-Thought).

2.2 Tokens y tokenización

Los modelos no procesan caracteres ni palabras completas directamente, sino **tokens**: unidades intermedias generadas por un algoritmo de tokenización, típicamente basado en *Byte Pair Encoding* (BPE) o en variantes como *SentencePiece*. Estos algoritmos construyen un vocabulario fijo (de decenas o cientos de miles de entradas) a partir de las subcadenas más frecuentes en un corpus de entrenamiento, de modo que las palabras habituales se representan con un solo token y las palabras raras, los términos técnicos o los nombres propios se descomponen en varios fragmentos.

Texto original:

"el prompt engineering es clave"



Cada modelo tiene su propio tokenizador: la misma frase puede fragmentarse de forma distinta según el vocabulario aprendido. El coste y el límite de contexto se miden en tokens, no en caracteres.

Figura 2. Ejemplo de tokenización de una frase y su representación como identificadores numéricos.

Esta mecánica tiene implicaciones muy prácticas para quien escribe prompts o integra un LLM en una aplicación:

- El **coste** de las API de LLM se factura casi siempre por token de entrada y de salida, no por carácter ni por palabra; un texto con muchos términos poco frecuentes (código, jerga médica o legal, idiomas con escritura no latina) puede consumir muchos más tokens de lo que su longitud en caracteres sugiere.
- El **límite de contexto** de un modelo se mide en tokens, por lo que la misma instrucción puede "caber" o no según el idioma y el vocabulario empleado.
- Las tareas que requieren contar caracteres, invertir cadenas o manipular texto letra a letra son intrínsecamente difíciles para un LLM, ya que su unidad atómica de percepción no es el carácter sino el token, que puede agrupar varias letras.

- Distintos modelos usan distintos tokenizadores: el número de tokens de un mismo texto puede variar de un proveedor a otro, lo que afecta tanto al coste como al margen disponible de contexto.

2.3 La ventana de contexto

La **ventana de contexto** (*context window*) es el número máximo de tokens que un modelo puede tener en cuenta simultáneamente entre entrada y salida. Todo lo que se envía al modelo —instrucciones de sistema, historial de la conversación, documentos recuperados, el prompt actual— compite por ese mismo presupuesto de tokens, y la respuesta generada también lo consume.




Figura 3. Composición típica de una ventana de contexto y estrategias habituales cuando se supera el límite.

Cuando una conversación o un documento superan la ventana de contexto disponible, es necesario aplicar alguna estrategia de gestión: truncar el historial más antiguo, resumirlo de forma progresiva, o recuperar únicamente los fragmentos más relevantes mediante técnicas de recuperación de información (véase el apartado 6.4 sobre RAG). Un error de diseño frecuente consiste en ignorar este límite y asumir que "quepa lo que quepa": esto provoca fallos silenciosos, truncamientos inesperados o, en el peor caso, la pérdida de las instrucciones de sistema si estas no se protegen adecuadamente.

BUENA PRÁCTICA

Cuando trabajes con documentos largos, resulta muy útil estimar de antemano el número de tokens del contexto (la mayoría de los SDK ofrecen utilidades de conteo, como `tiktoken` para los modelos de OpenAI) en lugar de descubrir el límite mediante un error en producción.

2.4 Parámetros de generación: temperature, top-p y top-k

Una vez calculada la distribución de probabilidad sobre el vocabulario para el siguiente token, el modelo debe decidir cuál emitir. Este paso, llamado **muestreo** (*sampling*), se controla mediante varios parámetros expuestos por las API de los proveedores:

- **temperature**: reescala los logits antes de aplicar la función *softmax*. Valores bajos (próximos a 0) concentran la probabilidad en los tokens más plausibles y producen salidas deterministas y conservadoras; valores altos (por encima de 1) aplanan la distribución y aumentan la diversidad y la creatividad, a costa de una mayor probabilidad de incoherencias.

- **`top\_p` (nucleus sampling)**: en lugar de considerar todo el vocabulario, restringe el muestreo al conjunto más pequeño de tokens cuya probabilidad acumulada supera el umbral **p** (por ejemplo, 0.9). Es una alternativa (o complemento) a **temperature** que se adapta dinámicamente a la "forma" de la distribución en cada paso.
- **`top\_k`**: restringe el muestreo a los **k** tokens más probables, descartando la larga cola de opciones improbables.
- **`max\_tokens`**: límite superior de tokens que el modelo puede generar en la respuesta; no afecta a la calidad del contenido, pero sí puede truncar la respuesta si se fija demasiado bajo.
- **`stop sequences`**: cadenas que, si aparecen en la salida, detienen la generación de inmediato; muy útiles para delimitar el final de una estructura esperada (por ejemplo, el cierre de un bloque JSON).




Figura 4. Efecto del parámetro *temperature* sobre la distribución de probabilidad del siguiente token.

Parámetro	Rango típico	Efecto al aumentar su valor	Cuándo usarlo
temperature	0.0 – 2.0	Mayor diversidad y creatividad; menor determinismo	0.0–0.3 para tareas factuales o código; 0.7–1.0 para redacción creativa
top_p	0.0 – 1.0	Se amplía el conjunto de tokens candidatos	Alternativa a temperature ; no se recomienda ajustar ambos a la vez de forma agresiva
top_k	1 – 100 (típico)	Se amplía el número de candidatos considerados	Control fino adicional, menos usado de forma aislada
max_tokens	depende del modelo	Permite respuestas más largas	Ajustar según el formato de salida esperado, para evitar truncamientos o gasto innecesario
stop	lista de cadenas	—	Delimitar el final de una estructura (JSON, lista, bloque de código)

Tabla 1. Parámetros habituales de las API de generación y su efecto práctico.

ADVERTENCIA

Bajar **temperature** a 0 no garantiza una salida idéntica en todas las ejecuciones ni en todos los proveedores: factores como el paralelismo en la inferencia pueden introducir pequeñas variaciones. Si se necesita reproducibilidad estricta, conviene comprobar la documentación específica del proveedor sobre semillas (**seed**) y determinismo.

2.5 Roles de la conversación: system, user y assistant

Los modelos conversacionales modernos no reciben un único bloque de texto plano, sino una secuencia estructurada de **mensajes**, cada uno etiquetado con un rol. Esta estructura, consolidada por las principales API del mercado, distingue típicamente tres roles:

- **system** (o "instrucciones de sistema"): define el comportamiento general, la personalidad, las restricciones y el marco de la conversación. Suele tener mayor peso relativo y no debería ser visible ni modificable por el usuario final.
- **user**: los mensajes que introduce la persona (o el sistema que actúa en su nombre) en cada turno de la conversación.
- **assistant**: las respuestas generadas por el modelo; incluirlas en el historial permite mantener la coherencia conversacional en turnos sucesivos.

Algunos proveedores añaden roles adicionales, como **tool** o **function**, para representar los resultados devueltos por una herramienta externa invocada por el modelo (véase el apartado 6.3). Aunque los nombres y detalles de implementación varían ligeramente entre proveedores, el patrón conceptual es el mismo, como resume la siguiente tabla.

Concepto	OpenAI (Chat Completions)	Anthropic (Messages API)	Google (Gemini)
Instrucción de sistema	rol system en la lista de mensajes	parámetro system independiente	system_instruction independiente
Turno del usuario	rol user	rol user	rol user
Turno del modelo	rol assistant	rol assistant	rol model
Resultado de herramienta	rol tool	bloque tool_result dentro de user	rol function

Tabla 2. Comparativa simplificada de roles de mensaje en distintas API de LLM conversacionales.

NOTA

Los ejemplos de código de este documento usan una API genérica de tipo "mensajes" muy similar a la de los principales proveedores; los nombres exactos de parámetros pueden variar ligeramente, pero los conceptos y la estructura son directamente trasladables.

3. Anatomía y principios de un buen prompt

Con los fundamentos anteriores ya es posible entender por qué determinadas estructuras de prompt funcionan mejor que otras. Este capítulo propone una anatomía general, aplicable a la inmensa mayoría de las tareas, y un conjunto de principios de diseño contrastados en la práctica.

3.1 Componentes de un prompt eficaz

Aunque no todos los prompts necesitan todos los componentes, la mayoría de los prompts robustos en entornos de producción combinan, en mayor o menor medida, los siguientes seis bloques:

Anatomía de un prompt bien construido




Figura 5. Componentes habituales de un prompt bien estructurado.

- **Rol / persona**: define desde qué perspectiva o con qué conocimiento experto debe responder el modelo (por ejemplo, "eres un revisor de código senior especializado en seguridad").

- **Contexto:** información de fondo necesaria para resolver la tarea: el dominio, el público destinatario, restricciones técnicas, datos previos relevantes.
- **Tarea / instrucción:** la acción concreta que se pide, formulada de la manera más explícita posible.
- **Formato de salida:** la estructura esperada de la respuesta (lista, tabla, JSON, longitud máxima, idioma, tono).
- **Ejemplos** (opcional, *few-shot*): pares de entrada/salida que ilustran el comportamiento esperado con más precisión que cualquier descripción abstracta.
- **Restricciones:** límites explícitos sobre lo que el modelo no debe hacer (no usar cierto vocabulario, no proponer cambios fuera de alcance, no inventar datos que no estén en el contexto).

No es necesario que estos componentes aparezcan siempre en el mismo orden ni con la misma extensión; lo importante es que el prompt contenga la información suficiente para que el modelo no tenga que "adivinar" lo que realmente se espera de él.

3.2 Claridad, especificidad y el principio de la "carga cognitiva cero"

El principio más importante del prompt engineering, y el que explica la mayoría de las mejoras de calidad observadas en la práctica, es la **especificidad**. Un modelo de lenguaje no puede leer la mente de quien escribe el prompt: solo puede trabajar con la información explícita en el contexto y con los patrones aprendidos durante su entrenamiento. Cuanto más ambigua sea una instrucción, mayor será el espacio de respuestas "razonables" que el modelo puede generar, y menor la probabilidad de que coincida con lo que realmente se necesitaba.

Prompt ambiguo	Prompt específico
"Mejora este texto"	"Reescribe este párrafo para un informe técnico dirigido a dirección: reduce su longitud a la mitad, elimina las repeticiones y mantén un tono formal en español de España"
"Escríbeme una función en Python"	"Escribe una función en Python 3.11, con <i>type hints</i> y docstring en formato Google, que reciba una lista de enteros y devuelva la mediana; incluye el manejo del caso de lista vacía lanzando <code>ValueError</code> "
"Resume este informe"	"Resume este informe en un máximo de 150 palabras, en tres párrafos: contexto, hallazgos principales y recomendaciones, sin usar tecnicismos financieros"

Tabla 3. Ejemplos de reformulación de un prompt ambiguo en uno específico.

Un buen ejercicio práctico es leer el propio prompt como si se recibiera por primera vez, sin conocer la intención original, y preguntarse qué interpretaciones alternativas serían igualmente válidas dado el texto tal cual está escrito. Cualquier ambigüedad detectada de esta forma es candidata a resolverse de forma explícita.

3.3 El papel del formato de salida

Especificar el formato de salida no es un detalle cosmético: cambia la forma en que el modelo organiza internamente su razonamiento. Pedir una respuesta en JSON, por ejemplo, obliga implícitamente a una estructura más disciplinada que pedir "una respuesta libre", y facilita enormemente la integración posterior en un sistema que procese esa salida de forma automática (*parsing*).

- Cuando la salida debe procesarse por otro programa, especifica el formato exacto (JSON, CSV, XML, Markdown) y, si es posible, incluye un ejemplo del esquema esperado.
- Cuando el formato es JSON, indica explícitamente qué hacer si algún campo no se puede determinar (por ejemplo, usar `null`) y evita pedir explicaciones adicionales fuera del propio JSON.
- Para tareas de razonamiento, considera separar explícitamente el "razonamiento" de la "respuesta final" (por ejemplo, mediante etiquetas), de forma que un sistema automatizado pueda extraer solo la parte relevante.
- El uso de delimitadores claros (etiquetas XML, comillas triples, marcadores tipo `###`) ayuda al modelo a distinguir qué partes del prompt son instrucciones y cuáles son datos a procesar.

TEXT

Eres un extractor de datos. Analiza la reseña de producto delimitada por `<reseña></reseña>` y devuelve EXCLUSIVAMENTE un JSON con este esquema:

```
{
  "sentimiento": "positivo" | "neutro" | "negativo",
  "puntuacion_estimada": number, // de 1 a 5
  "aspectos_mencionados": string[]
}
```

`<reseña>`

La batería dura muchísimo y la cámara es excelente, pero el terminal se calienta bastante al grabar vídeo en 4K durante más de 10 minutos.

`</reseña>`

3.4 Antipatrones frecuentes

Determinados patrones aparecen una y otra vez en prompts poco eficaces. Identificarlos ayuda a revisar prompts propios antes de llevarlos a producción.

Antipatrón	Por qué falla	Alternativa recomendada
Instrucciones contradictorias ("sé breve" + "explica todos los detalles")	El modelo debe resolver el conflicto por su cuenta, con resultados inconsistentes	Priorizar explícitamente qué restricción prevalece si hay tensión entre ellas
Negaciones como única guía ("no seas informal")	Es más difícil especificar por omisión que por afirmación	Indicar positivamente el comportamiento deseado ("usa un tono formal y profesional")

Antipatrón	Por qué falla	Alternativa recomendada
Prompts monolíticos para tareas multietapa	El modelo mezcla fases de razonamiento distintas en una sola pasada	Descomponer en varios prompts encadenados (véase el apartado 5.4)
Confiar en la memoria del modelo para datos actuales o específicos de la organización	El modelo puede alucinar datos plausibles pero incorrectos	Proveer el contexto explícitamente en el prompt (RAG, apartado 6.4)
No indicar qué hacer ante la incertidumbre	El modelo puede inventar una respuesta antes que admitir que no lo sabe	Instruir explícitamente: "si no dispones de información suficiente, indícalo en lugar de suponer"

Tabla 4. Antipatrones habituales en el diseño de prompts y su alternativa recomendada.

4. Técnicas fundamentales de prompting

Este capítulo cubre las técnicas más básicas y, a la vez, más utilizadas en la práctica diaria: cuántos ejemplos incluir, cómo asignar un rol al modelo y cómo estructurar prompts reutilizables mediante plantillas.

4.1 Zero-shot prompting

El **zero-shot prompting** consiste en pedir al modelo que realice una tarea sin proporcionarle ningún ejemplo resuelto, confiando en que el conocimiento adquirido durante su entrenamiento (y el ajuste para seguir instrucciones) sea suficiente para interpretar correctamente la petición. Es el enfoque más simple y económico en tokens, y suele funcionar bien para tareas comunes, bien delimitadas y que no dependen de un formato o estilo muy idiosincrático.

TEXT

Clasifica el siguiente comentario de atención al cliente en una de estas categorías: "reclamación", "consulta", "elogio". Responde solo con la categoría.

Comentario: "Llevo tres días esperando una respuesta y nadie me contesta."

El zero-shot funciona mejor cuanto más se aproxima la tarea a patrones muy representados en los datos de entrenamiento (clasificación de sentimiento, resúmenes genéricos, traducción entre idiomas comunes). Cuando la tarea exige un formato de salida muy específico, una taxonomía propia de la organización o un estilo particular, el rendimiento zero-shot suele degradarse y conviene pasar a un enfoque *few-shot*.

4.2 One-shot y few-shot prompting

El **few-shot prompting** incluye en el propio prompt uno o varios ejemplos resueltos de la tarea (pares entrada → salida) antes de presentar el caso real a resolver. Estos ejemplos actúan como una demostración concreta del comportamiento esperado, algo que suele ser mucho más eficaz que cualquier descripción abstracta, especialmente para fijar un formato de salida exacto o un estilo particular.




Figura 6. Comparación entre zero-shot, one-shot y few-shot prompting según el número de ejemplos incluidos.

TEXT

Extrae la entidad "producto" y su "precio" de cada frase, en formato JSON.

Frase: "La freidora de aire cuesta 79,99 euros."

Salida: {"producto": "freidora de aire", "precio": 79.99}

Frase: "El altavoz Bluetooth sale por 34,50 €."

Salida: {"producto": "altavoz Bluetooth", "precio": 34.50}

Frase: "La aspiradora robot tiene un precio de 249 euros."

Salida:

A la hora de elegir los ejemplos para un prompt *few-shot*, conviene tener en cuenta varias recomendaciones prácticas:

- **Representatividad:** los ejemplos deben cubrir la variabilidad real de los casos esperados, incluyendo casos límite (valores vacíos, formatos atípicos, ambigüedad).
- **Consistencia de formato:** todos los ejemplos deben seguir exactamente el mismo formato de salida que se espera para el caso real; cualquier inconsistencia se "contagia" a la respuesta.
- **Orden:** los modelos pueden mostrar cierta sensibilidad al orden de los ejemplos; en tareas críticas, merece la pena probar más de un orden y comparar resultados.
- **Cantidad:** no siempre "más ejemplos" implica mejor rendimiento; a partir de cierto punto, el coste en tokens crece sin una mejora proporcional, y en ocasiones un exceso de ejemplos muy similares reduce la capacidad de generalización a casos distintos.

4.3 Prompting basado en roles y persona

Asignar un **rol o persona** al modelo mediante la instrucción de sistema (o al inicio del prompt) ayuda a condicionar el vocabulario, el nivel de detalle y la perspectiva desde la que se aborda una tarea. No se trata de una simple decoración retórica: el modelo ajusta de forma medible su comportamiento en

función del rol asignado, porque ese rol activa patrones lingüísticos y de conocimiento asociados en los datos de entrenamiento.

TEXT

SYSTEM:

Eres un ingeniero de sistemas con 15 años de experiencia en Linux y automatización con Python. Respondes con precisión técnica, citas comandos exactos y adviertes de riesgos de seguridad cuando proceda. No simplifiques en exceso: el usuario es un profesional del sector.

USER:

¿Cómo puedo programar una tarea que se ejecute cada noche a las 2:00 y registre su salida en un archivo de log con fecha?

El rol es especialmente útil para: fijar el nivel de expertise esperado (evitando explicaciones innecesariamente básicas o, al contrario, demasiado técnicas), establecer un tono corporativo consistente en un producto con múltiples prompts, y delimitar la perspectiva desde la que se analiza un problema con múltiples enfoques posibles (por ejemplo, "analiza esta arquitectura desde el punto de vista de la seguridad", frente a "...desde el punto de vista del coste").

ADVERTENCIA

Asignar un rol no convierte al modelo en un experto infalible en esa materia ni sustituye una validación humana en dominios de alto riesgo (médico, legal, financiero, de seguridad). El rol condiciona el estilo y el enfoque, pero no garantiza la exactitud del contenido generado.

4.4 Plantillas y prompts parametrizados

En cualquier sistema de producción, los prompts rara vez son cadenas de texto fijas: se generan a partir de **plantillas** con variables que se rellenan en tiempo de ejecución. Esto permite reutilizar la misma estructura de prompt, ya validada y probada, para múltiples entradas distintas, y facilita enormemente el mantenimiento y la evaluación sistemática (capítulo 8).

PYTHON

```
from string import Template
```

```
PLANTILLA_RESUMEN = Template("""
```

```
Eres un asistente que resume documentos técnicos para perfiles no especializados.
```

```
Resume el siguiente documento en un máximo de $max_palabras palabras, en un tono $tono y en idioma $idioma. No incluyas información que no aparezca explícitamente en el texto original.
```

```
DOCUMENTO:
"""$documento"""
"""

prompt = PLANTILLA_RESUMEN.substitute(
    max_palabras=120,
    tono="cercano pero profesional",
    idioma="español de España",
    documento=texto_del_informe,
)
```

En sistemas más avanzados, estas plantillas suelen almacenarse de forma versionada (junto con el código, o en un sistema dedicado de gestión de prompts), de manera que cualquier cambio en una plantilla pueda auditarse, probarse contra un conjunto de casos de referencia y desplegarse de forma controlada, exactamente igual que cualquier otro cambio de código en producción (véase el capítulo 8).


5. Razonamiento explícito: técnicas intermedias

Las técnicas de este capítulo abordan un problema concreto: los LLM, al generar texto token a token, tienden a cometer errores en tareas que requieren varios pasos de razonamiento encadenados (aritmética, lógica, planificación), especialmente cuando se les pide la respuesta final de forma directa. Exponer el razonamiento intermedio de forma explícita mejora sistemáticamente el rendimiento en este tipo de tareas.

5.1 Chain-of-Thought (CoT): cadena de pensamiento

La técnica de **Chain-of-Thought** consiste en instruir al modelo para que exponga su razonamiento paso a paso antes de ofrecer la respuesta final, en lugar de "saltar" directamente a la conclusión. Al obligar al modelo a generar explícitamente los pasos intermedios, cada paso queda disponible como contexto para generar el siguiente, lo que reduce notablemente la tasa de error en tareas aritméticas, lógicas y de planificación con varios pasos.

Chain-of-Thought (CoT): el modelo explicita su razonamiento intermedio antes de responder



El razonamiento explícito reduce errores en tareas aritméticas, lógicas y de varios pasos.

Figura 7. Esquema de Chain-of-Thought: el modelo explicita su razonamiento antes de responder.

TEXT

Un tren sale de Madrid a las 09:15 y llega a Valencia a las 12:40.
Otro tren sale de Valencia a las 11:00 y llega a Madrid a las 14:20.
Si ambos trenes recorren la misma vía, ¿a qué hora aproximada se cruzan, asumiendo velocidad constante en ambos?

Resuelve el problema paso a paso, mostrando el razonamiento antes de dar la respuesta final.

La instrucción explícita ("resuelve paso a paso", "muestra tu razonamiento") es lo que se conoce como **CoT inducido por instrucción**. Existe también el CoT **few-shot**, en el que los propios ejemplos incluidos

en el prompt ya muestran el razonamiento paso a paso, lo cual suele ser aún más eficaz que la instrucción genérica, a costa de un prompt más largo.

5.2 Zero-shot CoT: "pensemos paso a paso"

Uno de los hallazgos más citados en la literatura de prompt engineering es que basta con añadir una frase tan simple como *"pensemos paso a paso"* (o su equivalente en inglés, *"let's think step by step"*) al final de una pregunta, sin proporcionar ningún ejemplo, para mejorar sustancialmente el rendimiento del modelo en tareas de razonamiento. Esta variante se conoce como **Zero-shot Chain-of-Thought**, y es una de las técnicas con mejor relación entre sencillez de implementación y ganancia de rendimiento.

TEXT

Pregunta: en una tienda hay 3 estanterías con 24 libros cada una.
Se venden 17 libros y se reponen 2 cajas de 6 libros cada una.
¿Cuántos libros hay en total ahora?

Pensemos paso a paso.

BUENA PRÁCTICA

Cuando el formato de salida final debe ser estricto (por ejemplo, un único número o un JSON), es buena práctica pedir explícitamente que el razonamiento se muestre primero y la respuesta final se indique al final de forma inequívoca, por ejemplo precedida de la etiqueta "RESPUESTA FINAL:", de modo que un programa pueda extraerla con facilidad.

5.3 Self-Consistency: autoconsistencia

La técnica de **Self-Consistency** parte de una observación sencilla: si se genera la misma pregunta varias veces con una temperatura mayor que cero, el modelo puede seguir distintos caminos de razonamiento y llegar, en ocasiones, a respuestas distintas. En lugar de quedarse con la primera respuesta generada, esta técnica genera **varios** razonamientos independientes para la misma pregunta y se queda con la respuesta que aparece con más frecuencia entre ellos (votación por mayoría).




Figura 8. Self-Consistency: se generan varios caminos de razonamiento y se elige la respuesta mayoritaria.

Esta técnica mejora la fiabilidad en tareas de razonamiento a costa de un coste computacional varias veces superior (tantas veces como caminos de razonamiento se generen), por lo que se reserva habitualmente para tareas de alto valor o alto riesgo, donde el coste adicional está justificado por la mejora en precisión.

PYTHON

```

from collections import Counter


def self_consistency(pregunta, cliente, n=5):
    respuestas = []
    for _ in range(n):
        salida = cliente.generar(
            prompt=f"{pregunta}\n\nPensemos paso a paso.",
            temperature=0.8,
        )
        respuesta_final = extraer_respuesta_final(salida)
        respuestas.append(respuesta_final)

    conteo = Counter(respuestas)
    respuesta_mayoritaria, votos = conteo.most_common(1)[0]
    return respuesta_mayoritaria, votos, len(respuestas)
  
```

5.4 Prompt Chaining: encadenamiento de prompts

El **Prompt Chaining** consiste en dividir una tarea compleja en una secuencia de subtareas más simples, cada una resuelta con su propio prompt, donde la salida de un paso se convierte en la entrada del siguiente. Es el equivalente, en el mundo del prompting, a descomponer un programa monolítico en funciones más pequeñas y testeables.

Prompt Chaining: la salida de cada prompt alimenta el siguiente



Divide una tarea compleja en sub tareas más simples, verificables y fáciles de depurar por separado.

Figura 9. Prompt Chaining: la salida de cada prompt alimenta al siguiente paso del pipeline.

Descomponer una tarea en una cadena de prompts aporta varias ventajas frente a un único prompt monolítico:

- **Depuración:** es posible inspeccionar la salida intermedia de cada paso y localizar en cuál de ellos se introduce un error.
- **Especialización:** cada prompt puede optimizarse de forma independiente (incluso usando modelos distintos según el coste/rendimiento requerido en cada paso).
- **Control de formato:** resulta más sencillo validar y, si es necesario, corregir la salida de un paso pequeño y bien delimitado que la de una tarea compleja resuelta de una sola vez.
- **Reutilización:** un mismo paso (por ejemplo, "traducir a inglés") puede reutilizarse en múltiples cadenas distintas.

PYTHON

```
def pipeline_informe(documento, cliente):
    datos = cliente.generar(
        f"Extrae en formato JSON las cifras clave (ingresos, costes, "
        f"margen) del siguiente documento:\n\n{documento}"
    )
    resumen = cliente.generar(
        f"A partir de estos datos JSON, redacta un resumen ejecutivo "
        f"de 3 frases:\n\n{datos}"
    )
    correo = cliente.generar(
        f"Redacta un correo profesional para dirección que incluya "
        f"este resumen ejecutivo:\n\n{resumen}"
    )
    return correo
```

5.5 Least-to-Most prompting

El **Least-to-Most prompting** es una variante especializada del encadenamiento de prompts pensada específicamente para problemas que se pueden descomponer en subproblemas de dificultad creciente, donde la solución de cada subproblema depende de la solución del anterior. En una primera

fase, se pide al modelo que **descomponga** el problema original en una lista ordenada de subproblemas más simples; en una segunda fase, se resuelven esos subproblemas uno a uno, en orden, proporcionando en cada paso las soluciones ya obtenidas como contexto adicional.

Esta técnica es especialmente eficaz en problemas de generalización composicional: tareas donde resolver el caso general requiere primero dominar casos más simples y combinarlos (por ejemplo, problemas matemáticos de varios niveles, generación de consultas SQL con subconsultas anidadas, o planificación de tareas con dependencias).

6. Técnicas avanzadas de agentes y razonamiento

Las técnicas anteriores mejoran la calidad del razonamiento de un LLM, pero siguen operando dentro de los límites de lo que el modelo "sabe" a partir de su entrenamiento y del contexto proporcionado. Este capítulo aborda técnicas que permiten a un modelo interactuar con el mundo exterior (herramientas, bases de datos, otros modelos) y explorar de forma más sofisticada el espacio de posibles soluciones.

6.1 ReAct: razonar y actuar

ReAct (*Reasoning and Acting*) es un patrón que entrelaza pasos de razonamiento explícito (*Thought*) con acciones concretas sobre el entorno (*Action*), como llamadas a una API o consultas a una base de datos, y la observación del resultado obtenido (*Observation*). El ciclo se repite tantas veces como sea necesario hasta que el modelo dispone de información suficiente para emitir una respuesta final.

El ciclo ReAct: razonar, actuar y observar




Figura 10. El ciclo ReAct: pensamiento, acción y observación, repetido hasta obtener la respuesta final.

Este patrón resuelve una limitación fundamental de los LLM: su conocimiento está "congelado" en el momento del entrenamiento y no incluye eventos posteriores ni datos privados de una organización. Al intercalar acciones reales (buscar en la web, consultar una base de datos interna, ejecutar código),

el modelo puede fundamentar su respuesta en información actualizada y verificable, en lugar de depender únicamente de lo memorizado durante el entrenamiento.

TEXT

Thought: para responder necesito saber el tipo de cambio EUR/USD actual.

Action: consultar_api_cambio(base="EUR", destino="USD")

Observation: 1 EUR = 1.087 USD

Thought: ya tengo el dato necesario para calcular la conversión.

Action: ninguna (información suficiente)

Respuesta final: 250 EUR equivalen aproximadamente a 271,75 USD al tipo de cambio actual (1 EUR = 1,087 USD).


NOTA

ReAct es el patrón conceptual subyacente a la mayoría de los "agentes" que ofrecen hoy los principales proveedores de LLM: la diferencia entre implementaciones suele residir en cómo se define el conjunto de herramientas disponibles y en los mecanismos de control (límite de iteraciones, validación de acciones) que se añaden alrededor del ciclo básico.

6.2 Tree of Thoughts (ToT): árbol de pensamientos

El **Tree of Thoughts** generaliza la idea de Chain-of-Thought al permitir explorar **varias** ramas de razonamiento en paralelo, en lugar de seguir un único camino lineal. En cada paso, el modelo genera varias continuaciones posibles ("pensamientos"), se evalúa la calidad o viabilidad de cada una (mediante el propio modelo actuando como evaluador, o mediante una función de coste externa), y se decide qué ramas explorar en profundidad y cuáles descartar (podar).

Tree of Thoughts: explorar, evaluar y podar varias ramas de razonamiento



Las ramas grises representan caminos evaluados y descartados por un criterio de valor.

Figura 11. Tree of Thoughts: exploración, evaluación y poda de varias ramas de razonamiento.

Esta técnica resulta especialmente valiosa en problemas donde la primera idea razonable no siempre es la correcta y donde el coste de "retroceder" (backtracking) tras un callejón sin salida es alto si no se detecta a tiempo: juegos de planificación, generación de código con múltiples estrategias de diseño posibles, o problemas creativos con criterios de evaluación claros. Su coste computacional es notablemente superior al de Chain-of-Thought simple, ya que implica generar y evaluar múltiples ramas, por lo que se reserva para problemas donde el coste de un error es alto.

6.3 Function calling y uso de herramientas

El **function calling** (también llamado *tool use*) permite que un LLM, en lugar de responder directamente en lenguaje natural, genere una llamada estructurada a una función predefinida —con sus argumentos en formato JSON—, que el sistema que orquesta la conversación ejecuta realmente, devolviendo el resultado al modelo para que este continúe la generación de la respuesta.




Figura 12. Secuencia de function calling: el modelo decide invocar una herramienta, el sistema la ejecuta y devuelve el resultado.

Para que esto funcione, se describe cada herramienta disponible mediante un esquema (nombre, descripción en lenguaje natural y parámetros con su tipo), de forma muy similar a como se documentaría una función en cualquier lenguaje de programación fuertemente tipado. El modelo utiliza esa descripción para decidir, de forma autónoma, si necesita invocar la herramienta y con qué argumentos.

PYTHON

```

herramientas = [
    {
        "name": "obtener_tiempo",
        "description": "Devuelve la previsión meteorológica de una "
            "ciudad para una fecha concreta.",
        "input_schema": {
            "type": "object",
            "properties": {
                "ciudad": {"type": "string"},
                "fecha": {"type": "string", "format": "date"},
            },
            "required": ["ciudad", "fecha"],
        },
    },
]

respuesta = cliente.mensajes.crear(
    modelo="modelo-chat-avanzado",
    mensajes=[{"role": "user", "content": "¿Qué tiempo hará mañana en Elche?"}],

```

```

tools=herramientas,
)

if respuesta.tipo_parada == "tool_use":
    llamada = respuesta.contenido_tool
    resultado = obtener_tiempo(**llamada.argumentos)
    # el resultado se devuelve al modelo como un nuevo mensaje de rol "tool"
    # para que redacte la respuesta final en lenguaje natural

```

BUENA PRÁCTICA

La calidad de las descripciones de las herramientas (nombre, descripción, nombres de parámetros) influye tanto en la decisión de invocarlas correctamente como la calidad de un buen prompt influye en cualquier otra tarea: trátalas como una interfaz pública que debe documentarse con el mismo rigor que una API REST.

6.4 RAG: generación aumentada por recuperación

RAG (*Retrieval-Augmented Generation*) combina un sistema de recuperación de información con un LLM generativo. En lugar de confiar en el conocimiento memorizado por el modelo durante su entrenamiento, la consulta del usuario se utiliza primero para **recuperar** los fragmentos de información más relevantes de una base de conocimiento propia (documentación interna, manuales, bases de datos), y esos fragmentos se incorporan al prompt como contexto antes de generar la respuesta final.




Figura 13. Pipeline típico de RAG: recuperación semántica de contexto seguida de generación fundamentada.

El componente de recuperación se basa habitualmente en **embeddings**: representaciones vectoriales del significado de un texto, generadas por un modelo especializado, de forma que textos

semánticamente similares quedan próximos en el espacio vectorial. La consulta del usuario se convierte también en un vector, y se buscan en una base de datos vectorial los fragmentos de documento cuyo vector esté más próximo (por ejemplo, mediante similitud del coseno).

- **Reduce las alucinaciones:** el modelo dispone de información verificable en el propio contexto, en lugar de depender de lo memorizado.
- **Permite conocimiento actualizado y privado:** la base de conocimiento puede actualizarse sin necesidad de reentrenar el modelo.
- **Facilita la trazabilidad:** es posible citar las fuentes concretas de las que procede cada afirmación de la respuesta.
- **Introduce nuevos puntos de fallo:** una mala segmentación de los documentos (*chunking*), una recuperación poco precisa o un contexto demasiado extenso pueden degradar la calidad final tanto como un mal prompt.

PYTHON

```
def responder_con_rag(pregunta, indice_vectorial, cliente, k=4):
    fragmentos = indice_vectorial.buscar(pregunta, top_k=k)
    contexto = "\n\n--\n\n".join(f.texto for f in fragmentos)

    prompt = f"""Responde a la pregunta usando EXCLUSIVAMENTE la
información del contexto. Si el contexto no contiene la respuesta,
indica que no dispones de información suficiente.

CONTEXTO:
{contexto}

PREGUNTA: {pregunta}
"""
    return cliente.generar(prompt)
```

6.5 Arquitecturas multiagente

En tareas suficientemente complejas, puede resultar más eficaz dividir el trabajo entre **varios agentes especializados**, cada uno con su propio prompt de sistema, su propio conjunto de herramientas y, en ocasiones, su propio modelo subyacente, coordinados por un **agente orquestador** que planifica, delega subtareas y consolida los resultados.




Figura 14. Arquitectura multiagente con un orquestador que delega en agentes especializados.

Este enfoque se inspira directamente en principios bien conocidos de la ingeniería de software, como la separación de responsabilidades y el diseño modular: cada agente puede optimizarse, probarse y depurarse de forma independiente, y el sistema en su conjunto resulta más fácil de razonar que un único prompt monolítico que intentase cubrir todos los aspectos del problema.

- **Ventajas:** especialización (prompts más cortos y precisos por agente), paralelización de subtareas independientes, y posibilidad de usar modelos distintos según el coste/rendimiento que requiera cada rol.
- **Riesgos:** mayor complejidad de orquestación, posibles bucles o bloqueos entre agentes, y un coste acumulado en tokens y llamadas a la API que debe controlarse cuidadosamente (por ejemplo, con límites de iteraciones y presupuestos máximos por tarea).

6.6 Meta-prompting y optimización automática de prompts

El **meta-prompting** consiste en usar un LLM para generar, criticar o mejorar otros prompts, en lugar de (o además de) usarlo directamente para resolver la tarea final. Un caso habitual consiste en pedir al modelo que, dado un prompt y varios ejemplos de casos en los que ha fallado, proponga una versión mejorada del propio prompt.

TEXT

Actúa como un experto en prompt engineering. Aquí tienes un prompt y tres casos donde produjo una respuesta incorrecta o incompleta.

PROMPT ACTUAL:

```
""{prompt_actual}""
```

CASOS FALLIDOS:

1. Entrada: {entrada_1} → Salida obtenida: {salida_1} → Esperado: {esperado_1}
2. Entrada: {entrada_2} → Salida obtenida: {salida_2} → Esperado: {esperado_2}
3. Entrada: {entrada_3} → Salida obtenida: {salida_3} → Esperado: {esperado_3}

Analiza qué ambigüedades o carencias del prompt actual explican estos fallos y propón una versión mejorada del prompt.

Existen también enfoques más automatizados y sistemáticos, como los frameworks de optimización de prompts basados en programas (por ejemplo, DSPy, mencionado en el capítulo 10), que tratan el propio prompt como un parámetro a optimizar frente a un conjunto de datos de validación y una métrica objetivo, de forma conceptualmente análoga a como se ajustan los hiperparámetros de un modelo de aprendizaje automático clásico.

7. Prompt engineering aplicado a la programación

Dado el perfil técnico de este documento, este capítulo se centra específicamente en el uso de LLM como herramienta de apoyo a tareas de desarrollo de software: generación de código, depuración, refactorización y generación de pruebas, junto con ejemplos completos de integración de la API tanto en **Python** como en **C**.

7.1 Generación de código

Los principios generales de especificidad se aplican con especial intensidad a la generación de código, donde la ambigüedad se traduce directamente en decisiones arbitrarias del modelo (versión del lenguaje, bibliotecas, manejo de errores, convenciones de estilo) que pueden no coincidir con las de tu proyecto.

- Especifica siempre el **lenguaje y la versión** (por ejemplo, "Python 3.11", "C99" o "C11"), ya que la sintaxis y las bibliotecas disponibles varían de forma relevante.
- Indica las **bibliotecas o frameworks permitidos** (o explícitamente prohibidos), y si el proyecto sigue un determinado *style guide* (PEP 8, un `.clang-format` propio, etc.).
- Especifica el **manejo de errores** esperado: ¿deben lanzarse excepciones, devolverse códigos de error, registrarse en un log?
- Pide **pruebas unitarias** junto con el código cuando sea relevante; a menudo mejora la calidad del propio código generado, porque obliga a un razonamiento más explícito sobre los casos límite.
- En C, especifica explícitamente la gestión de memoria esperada (quién libera qué recursos) y las convenciones de manejo de errores del proyecto (códigos de retorno, `errno`, etc.).

TEXT

Escribe una función en C11 que implemente una pila (stack) genérica mediante un array dinámico de punteros void*.

Requisitos:

- Prototipos: `stack_create`, `stack_push`, `stack_pop`, `stack_destroy`
- `stack_push` debe redimensionar el array automáticamente (doblando su capacidad) cuando se llene
- Todas las funciones que puedan fallar devuelven un código de tipo `StackStatus` (enum), nunca terminan el programa
- No debe haber fugas de memoria: `stack_destroy` libera el array interno, pero NO los elementos apuntados (son responsabilidad del llamador)
- Incluye comentarios estilo Doxygen en las cabeceras de función

7.2 Depuración y explicación de errores

Para depuración, la calidad de la respuesta depende en gran medida de la cantidad de contexto proporcionado: el mensaje de error completo (no solo la última línea), el fragmento de código

relevante, el comportamiento esperado frente al observado, y cualquier cambio reciente que pueda haber introducido el problema.

TEXT

Tengo el siguiente error en Python 3.11 al ejecutar un script de procesamiento de datos con pandas 2.1:

Traceback (most recent call last):

```
File "procesar.py", line 42, in <module>
    df["margen"] = df["ingresos"] / df["costes"]
File "...", line 123, in __truediv__
    ...
```

ZeroDivisionError: float division by zero

El DataFrame se carga desde un CSV de 50.000 filas. El error no ocurría la semana pasada; el único cambio ha sido incorporar datos de un nuevo proveedor.

1. Explica la causa más probable del error.
2. Propón dos formas de solucionarlo: una descartando filas problemáticas y otra sustituyendo el valor por NaN de forma explícita.
3. Indica cómo detectar cuántas filas se verían afectadas por cada estrategia antes de aplicarla.

Nótese la estructura: contexto completo del error, hipótesis sobre la causa (el cambio reciente), y una petición dividida en pasos numerados. Esta última técnica —descomponer la petición de depuración en subpreguntas concretas— reduce la probabilidad de que el modelo se centre solo en uno de los aspectos y ignore el resto.

7.3 Refactorización y revisión de código

En tareas de revisión y refactorización, resulta especialmente útil indicar el **objetivo** de la refactorización (legibilidad, rendimiento, seguridad, adecuación a un patrón de diseño concreto) y, cuando sea relevante, restringir explícitamente el alcance del cambio para evitar reescrituras innecesariamente amplias.

TEXT

Revisa el siguiente fragmento de C, centrándote EXCLUSIVAMENTE en posibles vulnerabilidades de seguridad relacionadas con el manejo de buffers y cadenas (desbordamientos, off-by-one, uso tras liberación).

No propongas cambios de estilo ni de nomenclatura. Para cada problema detectado, indica: la línea afectada, el riesgo concreto y una corrección mínima que no altere la interfaz de la función.

```
```c
void copiar_nombre(char *destino, const char *origen) {
 strcpy(destino, origen);
```

```
}
...
```

#### ADVERTENCIA

Un LLM puede pasar por alto vulnerabilidades sutiles o, al contrario, señalar falsos positivos con gran seguridad aparente. En código de seguridad crítica, la revisión asistida por LLM complementa, pero no sustituye, herramientas de análisis estático especializadas (linters de seguridad, sanitizers, auditoría humana experta).

## 7.4 Generación de tests

Pedir explícitamente cobertura de **casos límite** (entradas vacías, valores extremos, tipos inesperados, condiciones de carrera en código concurrente) suele producir baterías de pruebas mucho más completas que una petición genérica de "escribe tests para esta función".

#### PYTHON

```
def mediana(valores: list[float]) -> float:
 """Devuelve la mediana de una lista de números.

 Lanza ValueError si la lista está vacía.
 """
 if not valores:
 raise ValueError("la lista no puede estar vacía")
 ordenados = sorted(valores)
 n = len(ordenados)
 mitad = n // 2
 if n % 2 == 0:
 return (ordenados[mitad - 1] + ordenados[mitad]) / 2
 return ordenados[mitad]
```

#### TEXT

Genera tests con pytest para la función "mediana" (código adjunto arriba). Incluye, como mínimo:

- Lista con un número impar de elementos
- Lista con un número par de elementos
- Lista con un único elemento
- Lista vacía (debe verificar que se lanza ValueError)
- Lista con valores negativos y con valores duplicados
- Lista ya ordenada y lista en orden inverso

Usa nombres de test descriptivos en snake\_case y agrupa los casos mediante pytest.mark.parametrize donde tenga sentido.

## 7.5 Integración desde Python: ejemplo completo con la API de mensajes

El siguiente ejemplo muestra un cliente mínimo, pero realista, para interactuar con una API de tipo "mensajes" (el patrón común a los principales proveedores), incluyendo manejo de reintentos ante errores transitorios, control de tiempo de espera y extracción segura del contenido de la respuesta.

### PYTHON

```
import os
import time
import json
import httpx

API_URL = "https://api.ejemplo-llm.com/v1/messages"
API_KEY = os.environ["LLM_API_KEY"]

class ErrorLLM(Exception):
 pass

def llamar_llm(mensajes, modelo="modelo-chat-avanzado", temperature=0.2,
 max_tokens=1024, max_reintentos=3):
 """Invoca la API de mensajes con reintentos ante errores 429/5xx."""
 cabeceras = {
 "Authorization": f"Bearer {API_KEY}",
 "Content-Type": "application/json",
 }
 payload = {
 "model": modelo,
 "messages": mensajes,
 "temperature": temperature,
 "max_tokens": max_tokens,
 }

 ultimo_error = None
 for intento in range(1, max_reintentos + 1):
 try:
 resp = httpx.post(API_URL, headers=cabeceras, json=payload,
 timeout=30.0)
 if resp.status_code == 200:
 datos = resp.json()
 return datos["choices"][0]["message"]["content"]
 if resp.status_code in (429, 500, 502, 503):
 espera = 2 ** intento
 time.sleep(espera)
 ultimo_error = f"HTTP {resp.status_code}: {resp.text}"
 continue
 raise ErrorLLM(f"Error no recuperable: HTTP {resp.status_code}")
 except httpx.TimeoutException as e:
 ultimo_error = str(e)
 time.sleep(2 ** intento)
```

```

 raise ErrorLLM(f"Fallaron los {max_reintentos} intentos: {ultimo_error}")

def extraer_json(texto_respuesta):
 """Extrae de forma robusta un bloque JSON de la respuesta del modelo."""
 inicio = texto_respuesta.find("{")
 fin = texto_respuesta.rfind("}")
 if inicio == -1 or fin == -1:
 raise ValueError("La respuesta no contiene un objeto JSON")
 return json.loads(texto_respuesta[inicio:fin + 1])

if __name__ == "__main__":
 mensajes = [
 {"role": "system", "content": "Eres un extractor de datos que "
 "responde EXCLUSIVAMENTE en JSON."},
 {"role": "user", "content": (
 'Extrae nombre y edad: "Ana tiene 34 años y trabaja en '
 'ingeniería."'
)},
]
 salida = llamar_llm(mensajes)
 datos = extraer_json(salida)
 print(datos)

```

## 7.6 Integración desde C: llamadas HTTP con libcurl y construcción de JSON

Cuando la integración debe realizarse desde C —por ejemplo, en un sistema embebido con conectividad, una herramienta de línea de comandos de bajo nivel, o un componente que se integra en una base de código existente en C—, la llamada a una API de LLM basada en HTTP/JSON se realiza habitualmente combinando **libcurl** para la comunicación HTTP y una biblioteca ligera de JSON, como **cJSON**, para construir el cuerpo de la petición y analizar la respuesta.

```

C
/*
 * llm_client.c – cliente mínimo en C para una API de mensajes tipo LLM.
 * Dependencias: libcurl, cJSON
 * Compilación:
 * gcc llm_client.c -o llm_client -lcurl -lcjson
 */
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <curl/curl.h>
#include <cjson/cJSON.h>

#define API_URL "https://api.ejemplo-llm.com/v1/messages"

/* Buffer dinámico para acumular la respuesta HTTP */
struct Buffer {
 char *datos;
 size_t tam;

```

```

};

static size_t escribir_respuesta(void *contenido, size_t tam, size_t nmemb,
 void *userdata) {
 size_t tam_real = tam * nmemb;
 struct Buffer *buf = (struct Buffer *)userdata;

 char *nuevo = realloc(buf->datos, buf->tam + tam_real + 1);
 if (nuevo == NULL) {
 fprintf(stderr, "Error: sin memoria al ampliar el buffer\n");
 return 0; /* aborta la transferencia */
 }
 buf->datos = nuevo;
 memcpy(buf->datos + buf->tam, contenido, tam_real);
 buf->tam += tam_real;
 buf->datos[buf->tam] = '\0';
 return tam_real;
}

/* Construye el cuerpo JSON de la petición a partir del prompt */
static char *construir_payload(const char *system_prompt,
 const char *user_prompt) {
 cJSON *raiz = cJSON_CreateObject();
 cJSON_AddStringToObject(raiz, "model", "modelo-chat-avanzado");
 cJSON_AddNumberToObject(raiz, "temperature", 0.2);
 cJSON_AddNumberToObject(raiz, "max_tokens", 1024);

 cJSON *mensajes = cJSON_AddArrayToObject(raiz, "messages");

 cJSON *msg_sistema = cJSON_CreateObject();
 cJSON_AddStringToObject(msg_sistema, "role", "system");
 cJSON_AddStringToObject(msg_sistema, "content", system_prompt);
 cJSON_AddItemToArray(mensajes, msg_sistema);

 cJSON *msg_usuario = cJSON_CreateObject();
 cJSON_AddStringToObject(msg_usuario, "role", "user");
 cJSON_AddStringToObject(msg_usuario, "content", user_prompt);
 cJSON_AddItemToArray(mensajes, msg_usuario);

 char *texto = cJSON_PrintUnformatted(raiz);
 cJSON_Delete(raiz);
 return texto; /* el llamador debe liberar con free() */
}

/* Realiza la llamada HTTP y devuelve el contenido textual de la
 * respuesta del modelo, o NULL en caso de error. El resultado debe
 * liberarse con free(). */
char *llamar_llm(const char *api_key, const char *system_prompt,
 const char *user_prompt) {
 CURL *curl = curl_easy_init();
 if (!curl) {
 fprintf(stderr, "Error: no se pudo inicializar libcurl\n");
 return NULL;
 }

 char *payload = construir_payload(system_prompt, user_prompt);
 struct Buffer respuesta = { .datos = malloc(1), .tam = 0 };
 respuesta.datos[0] = '\0';

```

```

struct curl_slist *cabeceras = NULL;
cabeceras = curl_slist_append(cabeceras, "Content-Type: application/json");

char auth[512];
snprintf(auth, sizeof(auth), "Authorization: Bearer %s", api_key);
cabeceras = curl_slist_append(cabeceras, auth);

curl_easy_setopt(curl, CURLOPT_URL, API_URL);
curl_easy_setopt(curl, CURLOPT_HTTPHEADER, cabeceras);
curl_easy_setopt(curl, CURLOPT_POSTFIELDS, payload);
curl_easy_setopt(curl, CURLOPT_WRITEFUNCTION, escribir_respuesta);
curl_easy_setopt(curl, CURLOPT_WRITEDATA, &respuesta);
curl_easy_setopt(curl, CURLOPT_TIMEOUT, 30L);

CURLcode res = curl_easy_perform(curl);
char *resultado = NULL;

if (res != CURLE_OK) {
 fprintf(stderr, "Error de red: %s\n", curl_easy_strerror(res));
} else {
 cJSON *json_resp = cJSON_Parse(respuesta.datos);
 if (json_resp == NULL) {
 fprintf(stderr, "Error: respuesta no es JSON válido\n");
 } else {
 /* choices[0].message.content */
 cJSON *choices = cJSON_GetObjectItem(json_resp, "choices");
 cJSON *primero = cJSON_GetArrayItem(choices, 0);
 cJSON *mensaje = cJSON_GetObjectItem(primero, "message");
 cJSON *contenido = cJSON_GetObjectItem(mensaje, "content");
 if (cJSON_IsString(contenido)) {
 resultado = strdup(contenido->valuelstring);
 }
 cJSON_Delete(json_resp);
 }
}

free(payload);
free(respuesta.datos);
curl_slist_free_all(cabeceras);
curl_easy_cleanup(curl);
return resultado;
}

int main(void) {
 curl_global_init(CURL_GLOBAL_DEFAULT);

 const char *api_key = getenv("LLM_API_KEY");
 if (!api_key) {
 fprintf(stderr, "Define la variable de entorno LLM_API_KEY\n");
 return EXIT_FAILURE;
 }

 char *respuesta = llamar_llm(
 api_key,
 "Eres un asistente conciso que responde en una sola frase.",
 "¿Cuál es la capital de Portugal?"
);
}

```

```
if (respuesta) {
 printf("Respuesta del modelo: %s\n", respuesta);
 free(respuesta);
} else {
 fprintf(stderr, "No se obtuvo respuesta del modelo\n");
}

curl_global_cleanup();
return EXIT_SUCCESS;
}
```

**NOTA**

Como en cualquier código de red en C, es imprescindible comprobar el valor de retorno de cada operación (`curl_easy_init`, `realloc`, `cJSON_Parse`) y liberar cada recurso reservado en todos los caminos posibles de ejecución, incluidos los de error. El ejemplo anterior libera `payload`, el buffer de respuesta y la lista de cabeceras en todos los casos antes de retornar.

Este mismo patrón —construir un payload JSON, realizar una petición HTTP con libcurl y analizar la respuesta con cJSON— es directamente extensible a la implementación de *function calling* desde C: basta con inspeccionar en la respuesta si el modelo ha solicitado una llamada a herramienta, ejecutar la función C correspondiente y reenviar el resultado en un nuevo mensaje de rol `tool`, replicando en C la misma secuencia descrita en el apartado 6.3 para Python.

## 8. Evaluación, iteración y control de calidad de prompts

Un prompt que funciona bien en dos o tres pruebas manuales no es, todavía, un prompt de producción. Igual que el código, los prompts deben evaluarse de forma sistemática frente a un conjunto representativo de casos, con métricas explícitas, antes de considerarse listos para un entorno real.

### 8.1 Por qué evaluar los prompts de forma sistemática

Los LLM son sistemas estocásticos y sensibles a variaciones aparentemente menores en el prompt (orden de las instrucciones, elección de palabras, formato de los ejemplos). Sin un proceso de evaluación sistemático, es fácil caer en una falsa sensación de confianza basada en un puñado de pruebas manuales favorables, que no representan la variabilidad real de los casos que el sistema encontrará en producción, incluyendo casos límite, entradas adversas o simplemente formulaciones inusuales por parte de usuarios reales.

### 8.2 Métricas y criterios de evaluación

La métrica adecuada depende del tipo de tarea. Algunas de las más habituales son las siguientes:

Tipo de tarea	Métrica habitual	Comentario
Clasificación (sentimiento, categorías)	Exactitud, precisión, exhaustividad, F1	Requiere un conjunto de referencia etiquetado manualmente
Extracción estructurada (JSON)	Tasa de validez de esquema, exactitud campo a campo	Validar primero que el JSON parsea correctamente, después su contenido
Resumen / redacción libre	Evaluación humana, o "LLM como juez" con una rúbrica explícita	Las métricas automáticas de solapamiento léxico (ROUGE, BLEU) correlacionan débilmente con la calidad percibida
Generación de código	Porcentaje de tests que pasan, análisis estático, ejecución real	La ejecución real del código es la señal más fiable disponible
Agentes con herramientas	Tasa de éxito en la tarea completa, número de pasos, coste total	Evaluar el resultado final de extremo a extremo, no solo cada paso aislado

**Tabla 5.** Métricas habituales para evaluar prompts según el tipo de tarea.

La técnica de **"LLM como juez"** (*LLM-as-a-judge*) consiste en usar un modelo (idealmente distinto o más capaz que el evaluado) para puntuar la calidad de una respuesta según una rúbrica explícita, cuando la evaluación humana sistemática no es viable a gran escala. Es una técnica útil pero no infalible: hereda posibles sesgos del modelo evaluador y tiende a favorecer respuestas más largas o con un estilo determinado, por lo que conviene validar periódicamente su criterio frente a evaluación humana en una muestra.

### 8.3 Metodología de iteración

Un ciclo de mejora de prompts razonablemente disciplinado sigue, de forma aproximada, los siguientes pasos:

1. Definir un **conjunto de evaluación** representativo, incluyendo casos típicos y casos límite conocidos.
2. Establecer una **línea base** con el prompt actual (o con la versión más sencilla posible) y medir su rendimiento con la métrica elegida.
3. Analizar los **casos fallidos** en detalle para identificar patrones (¿fallan sistemáticamente entradas de cierto tipo? ¿el formato de salida es incorrecto o es el contenido?).
4. Formular una **hipótesis** concreta sobre la causa (ambigüedad, falta de ejemplos, formato de instrucción poco claro) y modificar un solo aspecto del prompt a la vez.
5. Volver a evaluar sobre el mismo conjunto y comparar contra la línea base, vigilando posibles **regresiones** en casos que antes funcionaban correctamente.
6. Repetir el ciclo hasta alcanzar un rendimiento aceptable, documentando cada versión relevante del prompt y su rendimiento asociado.

#### BUENA PRÁCTICA

Cambia un único elemento del prompt entre iteraciones siempre que sea posible. Modificar varias cosas a la vez (el rol, el formato y los ejemplos, todo junto) dificulta enormemente saber qué cambio concreto produjo la mejora o el empeoramiento observado.

### 8.4 Testing automatizado y regresión de prompts

De la misma manera que el código de producción se somete a pruebas automatizadas en cada cambio, los prompts críticos deberían contar con un conjunto de pruebas de regresión que se ejecute automáticamente ante cualquier modificación de la plantilla, del modelo empleado o de sus parámetros.

#### PYTHON

```
import pytest

CASOS_PRUEBA = [
 {"entrada": "Llevo tres días esperando respuesta y nadie contesta",
 "categoria_esperada": "reclamación"},
 {"entrada": "¿Tenéis stock de la talla M en azul?",
 "categoria_esperada": "consulta"},
 {"entrada": "El servicio ha sido excelente, repetiré seguro",
 "categoria_esperada": "elogio"},
]

@pytest.mark.parametrize("caso", CASOS_PRUEBA)
def test_clasificacion_comentarios(caso, cliente_llm):
```

```
categoria = clasificar_comentario(caso["entrada"], cliente_llm)
assert categoria == caso["categoria_esperada"], (
 f"Entrada: {caso['entrada']!r} -> obtenido {categoria!r}, "
 f"esperado {caso['categoria_esperada']!r}"
)

def test_salida_es_json_valido(cliente_llm):
 salida = extraer_datos_producto("La freidora cuesta 79,99 €", cliente_llm)
 assert isinstance(salida, dict)
 assert "producto" in salida and "precio" in salida
 assert isinstance(salida["precio"], (int, float))
```


En sistemas de mayor envergadura, estas pruebas se integran en la misma canalización de integración continua (CI) que el resto del código, de forma que un cambio en un prompt que provoque una regresión notable se detecte antes de llegar a producción, exactamente igual que ocurriría con un cambio de código convencional.

## 9. Seguridad, riesgos y buenas prácticas

Integrar un LLM en un sistema real introduce una superficie de riesgo específica, distinta de las vulnerabilidades clásicas del software, porque el propio lenguaje natural —incluido el que procede de fuentes no confiables— puede alterar el comportamiento del modelo. Este capítulo resume los riesgos más relevantes y las mitigaciones habituales.

### 9.1 Prompt injection: inyección de prompts

La **inyección de prompts** (*prompt injection*) consiste en introducir, dentro de un contenido que el modelo va a procesar como datos (un documento, una página web, un correo electrónico, el resultado de una herramienta), instrucciones diseñadas para alterar el comportamiento previsto del sistema, por ejemplo intentando que el modelo ignore sus instrucciones de sistema o revele información sensible.



**Figura 15.** Anatomía de un ataque de inyección de prompt a través de contenido externo no confiable.

Este riesgo es especialmente relevante en sistemas RAG y en agentes que procesan contenido de terceros (páginas web, documentos subidos por usuarios, correos electrónicos), ya que ese contenido comparte el mismo canal —texto en lenguaje natural— que las instrucciones legítimas, y el modelo no dispone, por diseño, de una forma absolutamente infalible de distinguir "instrucción" de "dato" dentro de una misma ventana de contexto.

Mitigación	Descripción
Delimitación explícita	Envolver el contenido no confiable en delimitadores claros (etiquetas XML, marcadores) e instruir explícitamente al modelo para tratar ese contenido como

Mitigación	Descripción
	datos, nunca como instrucciones
Privilegio mínimo	Limitar las herramientas y el alcance de acciones disponibles para el modelo al mínimo necesario para la tarea concreta
Validación de salida	Comprobar de forma programática que las acciones propuestas por el modelo (llamadas a herramientas, comandos) son coherentes y están dentro de lo permitido antes de ejecutarlas
Confirmación humana	Exigir confirmación explícita de una persona antes de ejecutar acciones sensibles o irreversibles (envío de datos, borrado, transacciones)
Modelos y clasificadores especializados	Emplear clasificadores dedicados a la detección de intentos de inyección sobre el contenido externo antes de incorporarlo al contexto

**Tabla 6.** Mitigaciones habituales frente a la inyección de prompts.

#### ADVERTENCIA

Ninguna de estas mitigaciones es, por sí sola, una garantía absoluta. La defensa en profundidad — combinar varias capas de protección — es el enfoque recomendado, igual que en cualquier otro ámbito de la seguridad informática.

## 9.2 Jailbreaking y mitigaciones

El **jailbreaking** designa las técnicas dirigidas específicamente a eludir las salvaguardas de seguridad de un modelo (por ejemplo, mediante juegos de rol elaborados, la fragmentación de una petición dañina en pasos aparentemente inocuos, o instrucciones que piden al modelo "ignorar todas las reglas anteriores"). A diferencia de la inyección de prompts, que suele explotar contenido de terceros, el jailbreaking parte típicamente del propio usuario que interactúa con el sistema.

Desde la perspectiva de quien construye un sistema sobre un LLM, las mitigaciones prácticas incluyen reforzar las instrucciones de sistema con recordatorios explícitos sobre los límites que no deben cruzarse, aplicar clasificadores de seguridad independientes tanto a la entrada como a la salida del modelo, limitar el alcance de las acciones automatizables sin supervisión humana, y realizar pruebas de resistencia (*red teaming*) periódicas frente a técnicas de jailbreaking conocidas.

## 9.3 Fuga de información y protección del system prompt

Un system prompt bien diseñado puede contener información sensible desde el punto de vista competitivo o de seguridad (lógica de negocio propietaria, claves de configuración, listas de reglas internas). Un usuario malicioso puede intentar que el modelo revele literalmente esas instrucciones mediante peticiones directas o indirectas.

- No incluir en el system prompt información que no se esté dispuesto a que, en algún escenario, acabe siendo visible.

- Evitar incrustar secretos (claves de API, credenciales) directamente en el prompt: deben residir en el sistema que orquesta la llamada, nunca en el texto enviado al modelo.
- Considerar instrucciones explícitas para que el modelo decline solicitudes de reproducir literalmente sus instrucciones de sistema.
- Auditar periódicamente mediante pruebas específicas si el system prompt puede extraerse mediante técnicas conocidas de extracción indirecta.

## 9.4 Alucinaciones, confabulación y sesgos

Una **alucinación** (o confabulación) es una afirmación generada por el modelo que resulta plausible desde el punto de vista lingüístico pero que es total o parcialmente falsa, no verificable, o no se sostiene en el contexto proporcionado. Este fenómeno es inherente a la naturaleza generativa y probabilística de los LLM, y no puede eliminarse por completo únicamente mediante el diseño del prompt, aunque sí puede reducirse notablemente.

- Fundamentar las respuestas en contexto explícito y verificable (RAG) en lugar de depender de la memoria paramétrica del modelo, especialmente para datos específicos, cifras o citas.
- Instruir explícitamente al modelo para que reconozca la incertidumbre ("si no tienes información suficiente, indícalo") en lugar de completar huecos de forma plausible.
- Pedir que la respuesta incluya referencias explícitas a las fuentes del contexto proporcionado, facilitando la verificación posterior.
- Aplicar Self-Consistency (apartado 5.3) en tareas de alto riesgo, ya que la discrepancia entre distintos caminos de razonamiento es, en sí misma, una señal de baja confianza.

Los **sesgos** son otro riesgo relevante: un LLM entrenado sobre grandes volúmenes de texto de origen humano puede reproducir y, en ocasiones, amplificar sesgos presentes en esos datos (de género, culturales, socioeconómicos). En aplicaciones sensibles (selección de personal, evaluación crediticia, ámbito judicial o sanitario), resulta imprescindible auditar sistemáticamente las respuestas del sistema frente a distintos subgrupos, y no depender exclusivamente de instrucciones del tipo "sé imparcial" en el prompt, que no garantizan por sí solas un comportamiento equitativo.

## 9.5 Buenas prácticas de seguridad: resumen

Ámbito	Buena práctica
Arquitectura	Aplicar el principio de privilegio mínimo: el modelo solo debe tener acceso a las herramientas y datos estrictamente necesarios para la tarea
Datos de entrada	Tratar cualquier contenido externo (web, documentos, correos) como no confiable y delimitarlo explícitamente frente a las instrucciones
Acciones sensibles	Exigir confirmación humana o validación programática antes de ejecutar acciones irreversibles o de alto impacto
Secretos	Nunca incrustar credenciales o claves en el prompt; gestionarlás en la capa de orquestación

Ámbito	Buena práctica
Monitorización	Registrar y auditar las interacciones (respetando la normativa de protección de datos aplicable) para detectar patrones de abuso
Evaluación continua	Incluir casos de seguridad (intentos de inyección, jailbreaking conocido) en el conjunto de pruebas de regresión del capítulo 8

**Tabla 7.** Buenas prácticas de seguridad al integrar LLM en sistemas de producción.

## 10. Herramientas y el ecosistema de prompt engineering

Este capítulo ofrece un mapa general, necesariamente simplificado, del ecosistema de herramientas que rodea al prompt engineering en la actualidad: las API de los proveedores de modelos, los frameworks de orquestación y las prácticas de gestión de prompts en producción.

### 10.1 SDKs y API de los principales proveedores

Todos los proveedores relevantes ofrecen un SDK oficial en Python (y, en muchos casos, también en JavaScript/TypeScript, Java o Go) que envuelve las llamadas HTTP a su API REST, gestiona la autenticación y ofrece utilidades adicionales (conteo de tokens, *streaming* de respuestas token a token, manejo estructurado de *function calling*). Aunque los detalles de cada API difieren, los conceptos —roles de mensaje, parámetros de muestreo, uso de herramientas— son, como se ha visto en capítulos anteriores, prácticamente universales.

#### NOTA

Para trabajar desde C, cuando no existe un SDK oficial en ese lenguaje, el patrón habitual es el mostrado en el apartado 7.6: llamadas HTTP directas con libcurl y manejo de JSON con una biblioteca ligera como cJSON.

### 10.2 Frameworks de orquestación

Por encima de las API de los modelos han surgido frameworks que facilitan tareas recurrentes: gestión de plantillas de prompts, encadenamiento de pasos, integración con bases de datos vectoriales para RAG, y definición de agentes con herramientas.

Framework	Enfoque principal	Cuándo puede resultar útil
LangChain	Encadenamiento de componentes (prompts, modelos, herramientas, memoria) mediante abstracciones reutilizables	Prototipado rápido de pipelines y agentes con múltiples integraciones ya disponibles
LlamaIndex	Especializado en indexación y recuperación de datos para RAG	Sistemas centrados principalmente en preguntas y respuestas sobre documentación propia
DSPy	Trata los prompts como parámetros optimizables mediante programas y métricas	Optimización sistemática y reproducible de prompts frente a un conjunto de evaluación
Semantic Kernel	Orquestación de "plugins"/funciones con LLM, orientado a integración empresarial en .NET/Python	Organizaciones con ecosistemas ya basados en .NET o Java
SDK nativos del	Acceso directo a la API sin capas de	Sistemas de producción donde se prioriza el

Framework	Enfoque principal	Cuándo puede resultar útil
proveedor	abstracción adicionales	control fino y minimizar dependencias

**Tabla 8.** Panorama simplificado de frameworks habituales del ecosistema (a fecha de redacción de este documento).

La elección entre usar un framework de orquestación o integrar directamente el SDK del proveedor depende del equilibrio entre velocidad de desarrollo inicial y control fino a largo plazo: los frameworks aceleran el prototipado, pero añaden una capa de abstracción adicional que, en sistemas de producción con requisitos muy específicos, puede llegar a dificultar la depuración y el control preciso del comportamiento.

### 10.3 Gestión de prompts en producción

Al igual que el código fuente, los prompts de un sistema en producción se benefician de disciplinas de ingeniería ya consolidadas:

- **Control de versiones:** almacenar los prompts junto con el código (o en un sistema dedicado) y registrar el historial de cambios.
- **Separación entre plantilla y configuración:** mantener separados el texto de la plantilla, los parámetros de muestreo y el modelo empleado, de forma que cada uno pueda ajustarse de forma independiente.
- **Registro de metadatos:** guardar, para cada llamada relevante, el identificador de versión del prompt, el modelo, los parámetros y la respuesta obtenida, facilitando la trazabilidad ante incidencias.
- **Despliegue gradual:** introducir cambios de prompts críticos de forma progresiva (por ejemplo, mediante *feature flags* o *A/B testing*) en lugar de sustituir el prompt en producción de golpe para toda la base de usuarios.

## 11. Casos prácticos completos

Este capítulo integra las técnicas anteriores en tres casos prácticos de extremo a extremo, representativos de escenarios habituales en la industria.

### 11.1 Caso 1: asistente de atención al cliente con RAG

**Objetivo:** responder preguntas de clientes sobre políticas de devolución, garantía y envíos, fundamentando cada respuesta en la documentación oficial vigente de la empresa, evitando invenciones y citando la política exacta aplicada.

**Diseño de la solución:** la documentación de políticas se segmenta en fragmentos coherentes (por política, no por número fijo de caracteres) y se indexa mediante embeddings en una base de datos vectorial. Ante cada consulta, se recuperan los fragmentos más relevantes y se construye un prompt que combina instrucciones de sistema, el contexto recuperado y la pregunta del cliente.

#### TEXT

##### SYSTEM:

Eres el asistente de atención al cliente de una tienda online. Responde EXCLUSIVAMENTE con información contenida en el CONTEXTO proporcionado. Si la pregunta no puede responderse con ese contexto, indica que vas a derivar la consulta a una persona del equipo humano, sin inventar ninguna política.

Cita entre corchetes el identificador de la política aplicada, por ejemplo [POL-DEV-03], al final de cada afirmación relevante.

##### CONTEXTO:

{fragmentos\_recuperados}

##### USER:

{pregunta\_del\_cliente}

**Consideraciones adicionales:** se aplica una capa de post-procesado que verifica que todo identificador de política citado en la respuesta ([POL-DEV-03], etc.) exista realmente entre los fragmentos recuperados, rechazando o regenerando la respuesta si se detecta una cita inventada; y se registra cada interacción (pregunta, fragmentos recuperados, respuesta) para su posterior auditoría y para alimentar el conjunto de evaluación del capítulo 8.

### 11.2 Caso 2: pipeline de extracción estructurada de datos

**Objetivo:** convertir facturas en PDF, con formatos heterogéneos entre proveedores, en registros estructurados (JSON) que alimenten un sistema contable, minimizando la intervención manual.

**Diseño de la solución:** se combina un paso previo de extracción de texto del PDF (fuera del alcance de este documento) con un prompt de extracción *few-shot*, que incluye ejemplos de facturas con estructuras distintas y su JSON correspondiente, y una validación programática posterior del esquema.

**PYTHON**

```

ESQUEMA_FACTURA = {
 "emisor": str, "numero_factura": str, "fecha": str,
 "base_imponible": float, "iva_porcentaje": float, "total": float,
}

def extraer_factura(texto_pdf, cliente):
 prompt = f"""Extrae los datos de la factura en JSON con EXACTAMENTE
estas claves: emisor, numero_factura, fecha (formato AAAA-MM-DD),
base_imponible, iva_porcentaje, total. Si un campo no aparece, usa null.

FACTURA:
"""{texto_pdf}"""

 salida = cliente.generar(prompt, temperature=0.0)
 datos = extraer_json(salida)
 validar_esquema(datos, ESQUEMA_FACTURA) # lanza excepción si no cumple
 return datos

```

**Consideraciones adicionales:** se fija `temperature=0.0` para maximizar la consistencia en una tarea puramente extractiva; los registros que no superan la validación de esquema, o donde el total no cuadra con la suma de base imponible más IVA, se enrutan a una cola de revisión manual en lugar de incorporarse automáticamente al sistema contable.

### 11.3 Caso 3: agente de análisis de código con herramientas

**Objetivo:** dado un repositorio de código, responder preguntas sobre su funcionamiento y proponer mejoras concretas, apoyándose en herramientas reales (búsqueda en el repositorio, ejecución de tests) en lugar de depender únicamente de lo que el modelo pueda inferir del fragmento de código pegado en el prompt.

**Diseño de la solución:** se define un agente ReAct (apartado 6.1) con tres herramientas: `buscar_en_repositorio(patron)`, `leer_archivo(ruta)` y `ejecutar_tests(modulo)`. El agente decide de forma autónoma qué herramienta invocar en cada paso, en función de la pregunta planteada, hasta reunir información suficiente para responder.

**TEXT**

```

Thought: para explicar cómo se calcula el descuento debo localizar
la función correspondiente en el repositorio.
Action: buscar_en_repositorio("def calcular_descuento")
Observation: encontrada en facturacion/descuentos.py, línea 18

Thought: necesito leer esa función para entender su lógica exacta.
Action: leer_archivo("facturacion/descuentos.py")
Observation: <contenido de la función calcular_descuento>

Thought: ya dispongo de información suficiente para responder y
para proponer una mejora sobre el caso de descuento negativo.

```

Respuesta final: la función `calcular_descuento()` aplica un [...]

**Consideraciones adicionales:** se establece un límite máximo de iteraciones del ciclo ReAct (por ejemplo, 8 pasos) para evitar bucles improductivos y controlar el coste; las acciones de escritura sobre el repositorio (si las hubiera) quedarían excluidas del conjunto de herramientas disponibles o, como mínimo, sujetas a confirmación humana explícita, conforme a los principios del capítulo 9.

## 12. Checklist final de buenas prácticas

A modo de resumen operativo de todo el documento, la siguiente tabla recoge una lista de comprobación por niveles, útil como referencia rápida antes de dar por válido un prompt o un sistema completo basado en LLM.

Nivel	Comprobación
Básico	¿El prompt especifica claramente rol, tarea, contexto y formato de salida esperado? (capítulo 3)
Básico	¿Se ha probado tanto en zero-shot como con ejemplos few-shot representativos, incluyendo casos límite? (capítulo 4)
Básico	¿Están fijados de forma explícita los parámetros de muestreo adecuados a la tarea (temperature, max_tokens, stop)? (capítulo 2)
Intermedio	¿Las tareas de razonamiento piden explícitamente los pasos intermedios antes de la respuesta final? (capítulo 5)
Intermedio	¿Las tareas complejas están descompuestas en una cadena de prompts más simples y verificables? (capítulo 5)
Avanzado	¿El sistema fundamenta sus respuestas en contexto verificable (RAG) cuando se requiere exactitud factual o datos propios? (capítulo 6)
Avanzado	¿Las herramientas expuestas al modelo siguen el principio de privilegio mínimo y las acciones sensibles requieren confirmación? (capítulo 9)
Avanzado	¿Existe un conjunto de evaluación y pruebas de regresión que se ejecuta ante cualquier cambio relevante de prompt o de modelo? (capítulo 8)
Seguridad	¿Se trata explícitamente como no confiable cualquier contenido externo incorporado al contexto? (capítulo 9)
Seguridad	¿El system prompt evita contener secretos y se han probado técnicas conocidas de extracción o jailbreaking? (capítulo 9)
Operación	¿Los prompts están versionados, documentados y su despliegue en producción es gradual y auditable? (capítulo 10)

**Tabla 9.** Checklist resumido de buenas prácticas de prompt engineering por nivel de madurez.

## 13. Glosario de términos

Término	Definición
Alucinación / confabulación	Afirmación generada por un LLM que resulta plausible pero es falsa o no se sostiene en el contexto proporcionado
Chain-of-Thought (CoT)	Técnica que induce al modelo a exponer su razonamiento paso a paso antes de la respuesta final
Embedding	Representación vectorial numérica del significado de un texto, usada para medir similitud semántica
Few-shot prompting	Inclusión de ejemplos resueltos en el prompt para ilustrar el comportamiento esperado
Fine-tuning	Ajuste adicional de los parámetros de un modelo preentrenado sobre un conjunto de datos específico
Function calling / tool use	Mecanismo por el que un modelo genera una llamada estructurada a una función externa
Jailbreaking	Técnicas dirigidas a eludir las salvaguardas de seguridad de un modelo
LLM	<i>Large Language Model</i> : modelo de lenguaje de gran escala entrenado sobre grandes volúmenes de texto
Prompt	Texto de entrada proporcionado a un modelo de lenguaje para obtener una respuesta
Prompt chaining	Encadenamiento de varios prompts donde la salida de uno alimenta al siguiente
Prompt injection	Introducción de instrucciones maliciosas dentro de contenido que el modelo procesa como datos
RAG	<i>Retrieval-Augmented Generation</i> : generación de texto fundamentada en información recuperada de una base de conocimiento
ReAct	Patrón que combina pasos de razonamiento explícito con acciones sobre herramientas externas
RLHF	<i>Reinforcement Learning from Human Feedback</i> : técnica de ajuste de modelos mediante retroalimentación humana
Self-Consistency	Técnica que genera varios razonamientos independientes y elige la respuesta más frecuente
System prompt	Instrucciones de nivel superior que definen el comportamiento general de un asistente conversacional
Temperature	Parámetro de muestreo que controla el grado de aleatoriedad de la generación de texto
Token	Unidad mínima de texto (palabra, subpalabra o carácter) que procesa un modelo de lenguaje
Tokenización	Proceso de dividir un texto en tokens antes de su procesamiento por el modelo
Tree of Thoughts (ToT)	Técnica que explora y evalúa varias ramas de razonamiento en paralelo
Transformer	Arquitectura de red neuronal basada en el mecanismo de autoatención, base de los LLM actuales

Término	Definición
Ventana de contexto	Número máximo de tokens que un modelo puede considerar simultáneamente entre entrada y salida
Zero-shot prompting	Petición de una tarea al modelo sin proporcionar ningún ejemplo resuelto

**Tabla 10.** *Glosario de términos empleados en este documento.*

## 14. Referencias y lecturas recomendadas

Este documento sintetiza principios y técnicas ampliamente documentados en la literatura técnica y académica sobre modelos de lenguaje y prompt engineering. Para profundizar, se recomienda consultar directamente la documentación oficial de los proveedores de modelos (que se actualiza con mayor frecuencia que cualquier documento estático) y la bibliografía académica original de cada técnica, entre la que destacan los trabajos que introdujeron la arquitectura Transformer, la técnica de Chain-of-Thought, el patrón ReAct, el método de Self-Consistency y el enfoque de Tree of Thoughts, todos ellos ampliamente citados en la literatura de procesamiento del lenguaje natural de la última década.

- Documentación oficial de las API de los principales proveedores de LLM (guías de prompting, referencia de parámetros y de function calling).
- Publicaciones académicas originales sobre la arquitectura Transformer y sobre cada una de las técnicas de prompting avanzadas descritas en los capítulos 5 y 6.
- Guías de buenas prácticas de seguridad para aplicaciones basadas en LLM publicadas por organizaciones especializadas en seguridad de aplicaciones.
- Documentación de los frameworks de orquestación mencionados en el capítulo 10, para conocer su API y capacidades más actualizadas.

### NOTA

El campo del prompt engineering evoluciona con rapidez: nuevos modelos, capacidades y técnicas aparecen de forma continua. Este documento recoge principios que han demostrado ser razonablemente estables a lo largo de distintas generaciones de modelos, pero conviene contrastar siempre las recomendaciones más específicas con la documentación vigente del proveedor y del modelo concretos que se estén utilizando.